

بسم الله الرحمن الرحيم



دانشکده مهندسی برق و کامپیوتر

یادگیری ماشین - فاز اول پروژه

سید مهدی رضوی - پونه شبیدینی

استاد : آقای دکتر توسلی پور - آقای دکتر ابوالقاسمی

سید مهدی رضوی - پونه شبیدینی

اردیبهشت ماه ۱۴۰۳

فهرست مطالب

۳	۱ مقدمه‌ای درباره سیگنال‌های EEG
۴	۲ مشکلات شناسایی الگوهای سیگنال‌های EEG
۵	۳ بعضی الگوریتم‌های معروف در زمینه شناسایی سیگنال‌های EEG
۷	۴ انجام بعضی از رویکردها برای پیش‌پردازش این سیگنال‌ها
۸	۵ مطرح کردن چند نکته در باب ویژگی‌های این سیگنال‌ها (خلاصه مقاله دوم)

فهرست تصاویر

در نوشتن این فاز از چند گزارش علمی و مقاله استفاده شده است که در پیوست این فایل موجود است.

۱ مقدمه‌ای درباره سیگنال‌های EEG

سیگنال‌های الکتروانسفالوگرافی (EEG) فعالیت‌های الکتریکی مغز هستند که از الکترودهایی که روی پوست سر قرار می‌گیرند ثبت می‌شوند. این سیگنال‌ها نشان‌دهنده فعالیت الکتریکی جمعیت‌های بزرگی از نورون‌ها در مغز هستند. در زمینه تصاویر حرکتی، سیگنال‌های EEG به ویژه جالب هستند زیرا قصد مغز را برای اجرای حرکات ارادی بدون اجرای حرکت واقعی منعکس می‌کنند. انواع سیگنال‌های EEG عبارتند از :

۱. Motor Imagery Signals این سیگنال‌های EEG هستند که در حالی که سوژه در حال تصور انجام یک کار حرکتی مانند حرکت دست یا پا است، ضبط می‌شود.

۲. Resting State Signals این سیگنال‌ها زمانی ضبط می‌شوند که سوژه در حالت استراحت است و هیچ کار خاصی را انجام نمی‌دهد. آنها به عنوان اندازه‌گیری‌های پایه برای مقایسه با سیگنال‌های مربوط به کار عمل می‌کنند.

۲ مشکلات شناسایی الگوهای سیگنال‌های EEG

۱. نویز سیگنال: سیگنال‌های EEG مستعد انواع مختلفی از نویز هستند، از جمله تداخل محیطی، مصنوعات ماهیچه‌ای و مصنوعات الکترونی، که می‌تواند الگوهای فعالیت مغز مورد نظر را پنهان کند.
۲. تنوع بین موضوعی: آناتومی و عملکرد مغز در بین افراد متفاوت است که منجر به تفاوت در الگوهای EEG حتی برای یک کار حرکتی می‌شود. این تنوع توسعه مدل‌های تعمیم یافته برای تشخیص تصاویر حرکتی را پیچیده می‌کند.
۳. دینامیک زمانی: تصاویر حرکتی شامل پویایی‌های زمانی پیچیده است، از جمله تغییرات در دامنه سیگنال، فرکانس و انسجام فاز، که چالش‌هایی را برای تشخیص دقیق الگو ایجاد می‌کند.
۴. وضوح فضایی محدود: الکترودهای EEG قدرت تفکیک فضایی محدودی دارند، که این موضوع را به چالش می‌کشد تا دقیقاً مناطق مغز درگیر در وظایف تصویربرداری حرکتی باشد.
۵. تطبیق بیش از حد (Overfitting): الگوریتم‌های تشخیص ممکن است بیش از حد با نویز یا ویژگی‌های خاص در داده‌های آموزشی مطابقت داشته باشند که منجر به عملکرد تعمیم ضعیف در داده‌های دیده نشده می‌شود.
۶. عدم تعادل داده‌ها: Data Imbalance مجموعه داده‌های EEG اغلب از عدم تعادل کلاس رنج می‌برند، جایی که یک کلاس (به عنوان مثال، تصاویر حرکتی) در مقایسه با سایرین کمتر ارائه می‌شود. این عدم تعادل می‌تواند طبقه بندی کننده را سوگیری کند و عملکرد آن را کاهش دهد.
۷. انتخاب ویژگی: شناسایی ویژگی‌های اطلاعاتی از سیگنال‌های EEG برای دقت طبقه بندی بسیار مهم است. با این حال، انتخاب ویژگی‌های مرتبط در عین کاهش لعنت ابعاد یک چالش باقی می‌ماند.
(dimension reduction)
۸. پردازش بلادرنگ: برنامه‌های کاربردی مبتنی بر EEG در زمان واقعی، مانند رابط‌های مغز و کامپیوتر (BCIs)، به الگوریتم‌هایی نیاز دارند که قادر به پردازش سریع و کارآمد داده‌ها هستند، که ممکن است محدودیت‌های محاسباتی بیشتری را تحمیل کند.

۳ بعضی الگوریتم‌های معروف در زمینه شناسایی سیگنال‌های EEG

۱. Linear Discriminant Analysis (LDA)

یک روش طبقه‌بندی که ترکیب خطی ویژگی‌هایی را پیدا می‌کند که به بهترین وجه کلاس‌های مختلف سیگنال‌های EEG را جدا می‌کند.

۲. Support Vector Machine (SVM)

۳. K-Nearest Neighbors (KNN)

۴. Artificial Neural Networks (ANNs)

مدل‌های یادگیری عمیق متشکل از گره‌های به هم پیوسته که استخراج ویژگی‌ها و طبقه‌بندی سیگنال‌های EEG را از طریق آموزش تکراری می‌آموزند.

۵. Convolutional Neural Networks (CNNs)

شبکه عصبی کانولوشنی

۶. Recurrent Neural Networks (RNNs)

شبکه‌های عصبی طراحی شده برای پردازش داده‌های متوالی، مناسب برای تجزیه و تحلیل دینامیک زمانی سیگنال‌های EEG.

۷. Long Short-Term Memory (LSTM)

نوعی RNN که اطلاعات را در توالی‌های طولانی حفظ می‌کند، که اغلب برای گرفتن وابستگی‌های زمانی در داده‌های EEG استفاده می‌شود.

۸. Gaussian Mixture Models (GMMs)

یک مدل احتمالی که توزیع سیگنال‌های EEG را به صورت مخلوطی از توزیع‌های گاوسی نشان می‌دهد که برای خوشه‌بندی و طبقه‌بندی مفید است.

۹. Hidden Markov Models (HMMs)

یک مدل آماری که حالت‌های زیربنایی سیگنال‌های EEG و انتقال آن‌ها را نشان می‌دهد که معمولاً برای تجزیه و تحلیل سری‌های زمانی و وظایف رمزگشایی استفاده می‌شود.

۱۰. Random Forest (RF)

۱۱. Extreme Learning Machines (ELMs)

یک شبکه عصبی پیش‌خور تک لایه با وزن‌های ورودی به‌طور تصادفی تولید شده و فعال‌سازی لایه پنهان ثابت، مناسب برای آموزش سریع و طبقه‌بندی سیگنال‌های EEG (شبکه عصبی تماماً متصل)

- Autoencoders

شبکه‌های عصبی برای یادگیری بازنمایی کارآمد داده‌های ورودی با بازسازی آن‌ها از یک فضای پنهان با ابعاد پایین‌تر، آموزش دیده‌اند که به طور بالقوه برای استخراج ویژگی از سیگنال‌های EEG مفید است

- Principal Component Analysis (PCA)

یک تکنیک کاهش ابعاد که جهت‌های متعامد حداکثر واریانس در داده‌های EEG را شناسایی می‌کند، که اغلب به عنوان یک مرحله پیش پردازش برای استخراج ویژگی استفاده می‌شود.

- Wavelet Transform

تبدیل موجک یک تبدیل ریاضی که برای تجزیه و تحلیل سیگنال‌های غیر ثابت مانند EEG با تجزیه آنها به باندهای فرکانسی مختلف در طول زمان استفاده می‌شود و امکان استخراج و طبقه‌بندی ویژگی‌ها را فراهم می‌کند.

- Empirical Mode Decomposition (EMD)

یک روش مبتنی بر داده برای تجزیه سیگنال‌های EEG به توابع حالت ذاتی، مفید برای استخراج اجزای نوسانی و شناسایی الگوها.

۴ انجام بعضی از رویکردها برای پیش پردازش این سیگنالها

۱. High-pass filtering

این موضوع حائز اهمیت زیادی خواهد بود که یک حد آستانه برای فیلترکردن سیگنالها موجود باشد که مدل ما درگیر شبیه سازی نویز نشود و از تطبیق بیش از حد جلوگیری شود.

۲. Line noise removal

مانند مورد قبل حذف کردن نویز از شبکه برای این خاطر اهمیت دارد که باز از تطبیق بیش از حد جلوگیری شود.

در زیر به چند تکنیک اشاره شده در این مقاله برای این موضوع اشاره کرده ایم که انشالله در پیاده سازی از آنها استفاده خواهیم کرد.

• Artifact rejection methods

• Data Quality Metric

• clean rawdata channel rejection

• clean rawdata ASR rejection

• eye movement and muscle rejection

Reference : EEG is better left alone

۵ مطرح کردن چند نکته در باب ویژگی‌های این سیگنال‌ها (خلاصه مقاله دوم)

توجه به چند چالش اساسی که در تحقیقات تصویرسازی حرکتی (MI) باید مد نظر قرار گیرد، ضروری است. یکی از این چالش‌ها، استفاده از دستگاه جمع‌آوری اطلاعات مورد بحث است که در اینجا الکتروانسفالوگرافی (EEG) مورد بررسی قرار می‌گیرد. این دستگاه با قابلیت حمل و نسبتاً قیمت مناسب، گزینه‌ی مناسبی برای تحقیقات سریع و ارزان می‌باشد. با این حال، این دستگاه در انتقال اطلاعات مکانی ضعیف عمل می‌کند و برای افرادی که نمی‌توانند در وضعیت نشسته شرکت کنند، مناسب نیست. از جمله افرادی که ممکن است برای آزمایشات MI قابلیت نگهداری در وضعیت نشسته را نداشته باشند، افرادی هستند که از سکتة مغزی یا آسیب جدی به نخاع فلج شده‌اند. همچنین، افرادی با نقص‌های عصبی دیگر نیز ممکن است نتوانند در چنین موقعیتی آزمایشات انجام دهند یا از رابط مغز-کامپیوتر (BCI) در این وضعیت استفاده کنند.

از طرف دیگر، انتخاب و استفاده از تکنیک‌های استخراج و انتخاب ویژگی و طبقه‌بندی برای تحلیل داده‌های MI نیز چالش‌های خود را ارائه می‌دهد. انتخاب این تکنیک‌ها باید با در نظر گرفتن حالت کاربردی - آنلاین یا آفلاین - صورت گیرد. برخی از تکنیک‌ها در حالت آفلاین به خوبی عمل می‌کنند اما در حالت آنلاین عملکرد آنها کاهش می‌یابد. همچنین، مدت زمان یک چرخه از نشانه تا بازخورد باید در نظر گرفته شود. انجام مکرر آزمایشات طولانی ممکن است غیر قابل تحمل باشد. نرخ انتقال اطلاعات هم از اهمیت بسیاری برخوردار است. انتخاب بین رویکردهای سنتی و یادگیری عمیق نیز با دقت باید صورت گیرد.

چالش‌های دیگری نیز در انجام یک مطالعه MI وجود دارد، از جمله استفاده‌پذیری BCI برای جمعیت هدف. هرچند برخی از مطالعات MI به دنبال ارائه مکانیسم‌های ترمیمی یا ارتباطی برای جمعیت ناسالم هستند، اما باید توجه داشت که ترکیبات عصب‌شناختی افراد ناسالم ممکن است با جمعیت سالم متفاوت باشد. بنابراین، BCI‌های پیاده‌سازی شده بر اساس سیگنال‌های افراد سالم، ممکن است برای استفاده در افراد ناسالم مناسب نباشند. با وجود چالش‌هایی که پژوهشگران BCI در انتخاب پیاده‌سازی BCI با آنها مواجه هستند، امکانات بهبود پیاده‌سازی BCI فراوان است. به عنوان مثال، معرفی دستگاه‌های MEG قابل حمل یک نقطه عطف بود. این نشان می‌دهد که با تلاش مداوم در زمینه EEG، نسخه‌های کوچکتر آن ممکن است به مرور زمان رایج شوند. وظایفی که به دلیل محدودیت پایداری مکانی در EEG به عنوان غیرممکن تلقی می‌شوند، ممکن است ممکن شوند. همچنین، تکنیک‌های پردازش مبتنی بر هندسه ریمانی و طبقه‌بندها، به طور فزاینده‌ای متداول می‌شوند و این می‌تواند به مبارزه با برخی از چالش‌های پیاده‌سازی BCI کمک کند. به علاوه، تکنیک‌های یادگیری انتقالی که به طور فزاینده‌ای استفاده می‌شوند، فرصت‌هایی برای بهبود در تحلیل MI ارائه می‌دهند. استفاده از شبکه‌های پیش آموزش داده شده یادگیری انتقالی از جمله، Inception VGG و Residual networks نیز برای پردازش EEG استفاده شده‌اند. استفاده از یادگیری انتقالی زمان آموزش مدل را به طور قابل توجهی کاهش می‌دهد و انعطاف پذیری بالایی دارد. از طریق یادگیری انتقالی، افراد دیگر نیازی به گذراندن دوره‌های طولانی کالیبراسیون ندارند که باعث کاهش احتمال خستگی می‌شود. با این کار، افراد می‌توانند به سرعت بازخورد دریافت کنند و عملکرد سیستم به مرور زمان افزایش می‌یابد.

بر اساس تحقیقات اخیر، تلاش‌هایی برای بهبود عملکرد طبقه‌بندی افراد با کارایی پایین در BCI با استفاده از روش‌های یادگیری عمیق (مانند شبکه‌های عصبی کانولوشنال) صورت گرفته است، زیرا این افراد قادر به تولید فعالیت‌های ERD/ERS مقابل قطبی قوی‌تر نمی‌باشند. تحقیقات BCI با هدف بهبود عملکرد می‌تواند به دو عامل فنی (بهبود الگوریتم‌ها برای استخراج و طبقه‌بندی ویژگی‌ها) یا عوامل انسانی (عواملی که بر کیفیت تولید الگوهای EEG تأثیر می‌گذارند) تمرکز کند. عوامل انسانی به نسبت کمتر مورد مطالعه قرار گرفته‌اند، اما بسیاری از تحقیقات سعی در بهبود عملکرد MI-BCIs با استفاده از رویکرد عوامل انسانی داشته‌اند.

Reference : Motor Imagery : A review of Esisting Techniques , Challenges and Potentials