

(a) فلات. زمانی که تعداد داده ها کم باشد، مدل های پیچیده به راحتی دچار overfitting می شوند.

(b) درخت، مدل های ساده تر به ازای ~~دیتا~~ دیتا است های مختلف کمتر تغییر می کنند و لذا واریانس کمتری دارند و خطای بایاس بیشتری دارند.

(c) درخت، زیرا در تخمین نواحی بزرگ از دانش بیشترین میزان استفاده کرد و فقط وابسته به داده ها نیست.

(d) درخت: $I(X;Y) = 0 \Leftrightarrow X \perp Y \Rightarrow$
 ~~$E[XY] = E[X]E[Y]$~~
 $E[XY] = E[X]E[Y]$

(e) درخت، زیرا منظم باز باعث کاهش پیچیدگی مدل می شود.

(f) درخت، زیرا توزیع احتمال هر دو کلاس گاوسی با مائرس کوواریانس I می شود. همین مائرس های کوواریانس یکسان است، لذا مرز جدا کننده خطی می شود.

۱۹ غلط - الگوریتم پرسپترون همواره مرز خطی جدا کننده را در صورت

وجود می یابد.



۲۰۱۳

۱۳۹۶/۱

الف) $\log P(D|\lambda) = \log \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \sum_{i=1}^n (x_i \log \lambda - \lambda - \log x_i!)$

$$= \log \lambda \sum_{i=1}^n x_i - n\lambda - \sum_{i=1}^n \log x_i!$$

ب) $\frac{\partial \log P(D|\lambda)}{\partial \lambda} = \frac{1}{\lambda} \sum_{i=1}^n x_i - n = 0 \Rightarrow \hat{\lambda}_{ML} = \frac{1}{n} \sum_{i=1}^n x_i$

ج) $P(\lambda|D) = \frac{P(D|\lambda) P(\lambda)}{P(D)} \propto P(D|\lambda) P(\lambda)$

$$= \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} c \lambda^{\alpha-1} e^{-\beta \lambda}$$

$$= c' \lambda^{\sum x_i + \alpha - 1} e^{-(n+\beta)\lambda}$$

$$= c' \lambda^{\alpha'-1} e^{-\beta' \lambda} = \text{Gamma}(\lambda | \alpha', \beta')$$

$$\alpha' = \sum_{i=1}^n x_i + \alpha \quad \beta' = n + \beta$$

د) به ازاي توزيع بين از عين توزيع عين شده است.

ه) $\lambda_{MAP} = \arg \max_{\lambda} P(\lambda|D) = \frac{\alpha'-1}{\beta'}$

و) $\lim_{n \rightarrow \infty} \frac{\sum_{i=1}^n x_i + \alpha - 1}{n + \beta} = \frac{\sum x_i}{n} = \hat{\lambda}_{ML}$

ز) به ازاي توزيع



الف) $L(\omega) = \sum_{i=1}^n (e^{\omega x_i} - y_i)^2$

ب)

$$\frac{\partial L}{\partial \omega} = \sum_{i=1}^n 2x_i e^{\omega x_i} (e^{\omega x_i} - y_i)$$

$$\Rightarrow \omega_{t+1} = \omega_t - 2\eta \sum_{i=1}^n x_i e^{\omega_t x_i} (e^{\omega_t x_i} - y_i)$$

ج) (د)

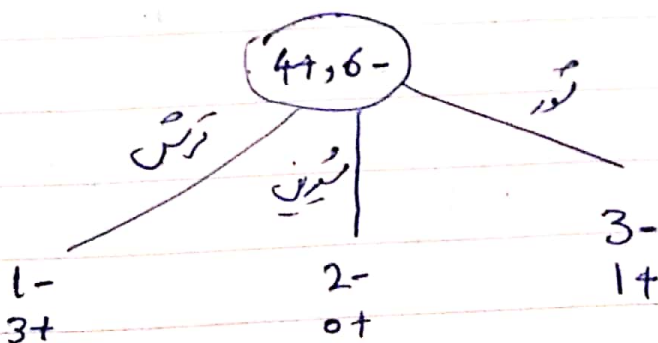
$$\frac{\partial L}{\partial \omega} = 0 \Rightarrow \sum_{i=1}^n x_i e^{2\omega x_i} = \sum_{i=1}^n y_i x_i e^{\omega x_i}$$

الف)

$$P(y = \text{غروب}) = \frac{4}{10}$$

$$\Rightarrow H(y) = -\frac{4}{10} \log \frac{4}{10} - \frac{6}{10} \log \frac{6}{10}$$

ب)



$$P(y=+ | \text{آفتاب}) = \frac{3}{4}$$

$$P(y=+ | \text{سحاب}) = 0$$

$$P(y=+ | \text{سور}) = \frac{1}{4}$$

۱۳۹۶ /

$$-\frac{3}{4} \log \frac{3}{4} - \frac{1}{4} \log \frac{1}{4}$$



$$H(y|طعم) = \frac{4}{10} H(\frac{3}{4}) + \frac{2}{10} \overbrace{H(0)}^0 + \frac{4}{10} H(\frac{1}{4})$$

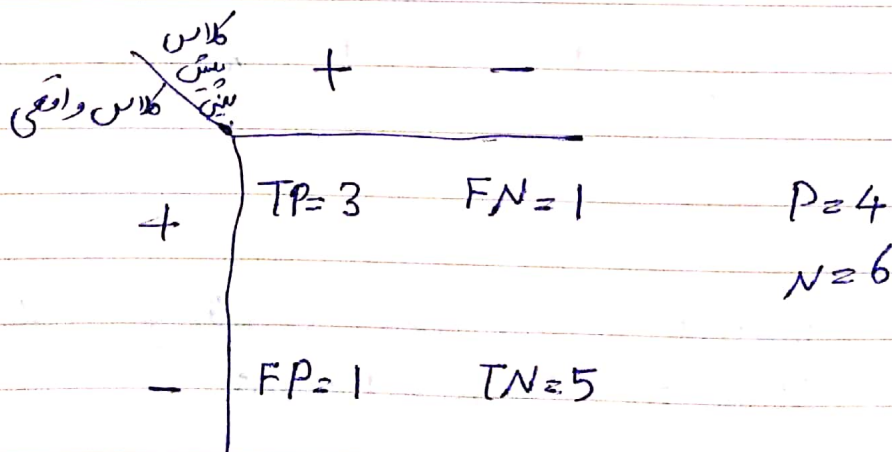

$$I(y; طعم) = H(y) - H(y|طعم)$$

$$= -\frac{4}{10} \log \frac{4}{10} - \frac{6}{10} \log \frac{6}{10} - \frac{8}{10} \left(-\frac{3}{4} \log \frac{3}{4} - \frac{1}{4} \log \frac{1}{4} \right)$$

راه دوم: مستقیماً از رابطه زیر حجم می‌توان استفاده کرد:

$$H(y|x) = \sum_{x,y} P(x,y) \log P(y|x)$$

(ج)



$$\text{recall} = \frac{TP}{P} = \frac{3}{4}$$

$$\text{precision} = \frac{TP}{TP+FP} = \frac{3}{4}$$

$$\text{specificity} = \frac{TN}{N} = \frac{5}{6}$$

$$\text{acc} = \frac{TP+TN}{n} = \frac{8}{10}$$

۱۳۹۶/ ۱

سوال ۵ : مرز از رابطه زیر بدست آید :




$$\frac{P(y=0|x)}{P(y=1|x)} = \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}}$$

~~$$\frac{P(x|y=0)}{P(x|y=1)} = \frac{P(y=0)}{P(y=1)}$$~~

$$\Rightarrow \frac{P(x|y=0) P(y=0)}{P(x|y=1) P(y=1)} = \frac{P(x|y=0)}{P(x|y=1)} = \frac{x^2/9}{2x/9} = \frac{x}{2}$$

$$\frac{x}{2} = \frac{\lambda_{12} - \lambda_{22}}{\lambda_{21} - \lambda_{11}} = \frac{4}{6} \Rightarrow \boxed{x = \frac{4}{3}}$$



سوال ۶

الت - overfitting : \downarrow drop out
Stochastic Gradient Descent

ب

$$n \rightarrow \infty$$

$$k \rightarrow \infty$$

$$k/n \rightarrow 0$$