

## سوال ۱

- الف) غلط، خطای بایس نامی از انتخاب مدل استباه (ساده) است و با افزایش داده نمی توان آن را کاهش داد.
- ب) درست، افزودن منظم ساز باعث ساده تر شدن مدل می شود و لذا خطای بایس <sup>از آن</sup> کاهش می یابد. مدل های ساده تر معمولا داریان کمتری دارند، بنابراین خطای داریان کاهش می یابد.
- ج) غلط، الگوریتم ID3 در واقع یک الگوریتم عریضه است و لزوما درخت بهینه را نمی یابد.
- د) غلط، در حالت کلی تعاضد دو تابع کرنل، یک کرنل معین نیست و می توان نشان داد که قضیه Mercer برای آن برقرار نیست.
- ه) درست، زیرا:

$$\phi(x) = \begin{bmatrix} x_1^2 \\ \sin x_2 x_3 \end{bmatrix} \Rightarrow g(x) = w^T \phi(x)$$

$$w = \begin{bmatrix} \alpha_1 \\ \alpha_2 \end{bmatrix}$$

ف) غلط، در صورتی که توزیع اصلی همگرا می شود  $v_n \rightarrow 0$  و  $n v_n \rightarrow \infty$

گ) درست، زیرا روش SVM فقط به بردارهای پشتیبان (support vectors) حساس است و اهمیتی ندارد که از هر کلاس چه تعداد نمونه وجود دارد.

## سوال ۲

الف)

$$L(\lambda) = \log P(D|\lambda) = \sum_{i=1}^n \log P(x_i|\lambda) = \sum_{i=1}^n \log(e^{-\lambda x_i})$$

$$= \sum_{i=1}^n \log 1 - \lambda x_i = n \log 1 - \lambda \sum_{i=1}^n x_i$$

$$\frac{dL(\lambda)}{d\lambda} = \frac{n}{1} - \sum_{i=1}^n x_i = 0 \Rightarrow \boxed{\hat{\lambda}_{ML} = \frac{n}{\sum_{i=1}^n x_i}}$$

(۱)

ب)

$$\begin{aligned}
 P(\lambda|D) &\propto P(D|\lambda)P(\lambda) = \prod_{i=1}^n P(x_i|\lambda)P(\lambda) \\
 &= \prod_{i=1}^n \lambda e^{-\lambda x_i} c \lambda^{\alpha-1} e^{-\beta \lambda} = c \lambda^n e^{-\lambda \sum_{i=1}^n x_i} e^{-\beta \lambda} \lambda^{\alpha-1} \\
 &= c \lambda^{n+\alpha-1} e^{-\lambda(\beta + \sum_{i=1}^n x_i)} = \text{Gamma}(\lambda | \underbrace{n+\alpha}_{\alpha_{\text{new}}}, \underbrace{\beta + \sum_{i=1}^n x_i}_{\beta_{\text{new}}})
 \end{aligned}$$

ج) بله، همانطور که در قسمت قبل می‌بینید، توزیع احتمال پس از رفع توزیع احتمال پیشین می‌شود است.

د)

$$\hat{\lambda}_{\text{MAP}} = \arg \max_{\lambda} P(\lambda|D) = \frac{\alpha_{\text{new}} - 1}{\beta_{\text{new}}} = \frac{n + \alpha}{\beta + \sum_{i=1}^n x_i}$$

ه) بله، زیرا

$$\lim_{n \rightarrow \infty} \hat{\lambda}_{\text{MAP}} = \lim_{n \rightarrow \infty} \frac{n + \alpha}{\beta + \sum_{i=1}^n x_i} = \cancel{\lim_{n \rightarrow \infty} \frac{n}{\sum_{i=1}^n x_i}} = \lim_{n \rightarrow \infty} \hat{\lambda}_{\text{ML}}$$


مسئله ۳


در ناصیه‌ی مربوط به کلاس ۰ داریم،

$$P(x|y=0) \quad P(y=0|x) \geq P(y=1|x) \Rightarrow P(x|y=0)P(y=0) \geq P(y=1|x)P(y=1)$$

$$\Rightarrow P(x|y=0) \geq P(y=1|x) \Rightarrow \frac{x^2}{9} \geq \frac{x}{9} + \frac{1}{6} \Rightarrow 2x^2 - 2x - 3 \geq 0$$

$$x_1, x_2 = \frac{1 \pm \sqrt{1+6}}{2}$$





$$\begin{aligned}
 \text{margin} = h &= \|\vec{x_2 x_1}\|_2 \cos \theta \\
 &= \frac{\|\vec{x_2 x_1}\|_2 \|\vec{w}\|_2 \cos \theta}{\|\vec{w}\|_2} \\
 &= \frac{\langle \vec{x_2 x_1}, \vec{w} \rangle}{\|\vec{w}\|_2} = \frac{\vec{w}^T (\vec{x_1} - \vec{x_2})}{\|\vec{w}\|_2} \\
 &= \frac{\overbrace{\vec{w}^T \vec{x_1} + b}^1 - \overbrace{\vec{w}^T \vec{x_2} - b}^{-1}}{\|\vec{w}\|_2} = \frac{2}{\|\vec{w}\|_2}
 \end{aligned}$$

(ب) با استفاده از رابطه  $\vec{w} = \sum_{i=1}^n \lambda_i y_i \vec{x_i}$  مقدار بردار  $\vec{w}$  بدست می آید. سپس با استفاده از یکی از بردارهای پشتیبان (نمونه‌هایی که روی خط margin قرار گرفته‌اند، مقدار  $b$  (عرض از مبدأ) را محاسبه می‌کنیم:

$$\vec{w}^T \vec{x_j} + b = y_j \Rightarrow \boxed{b = y_j - \vec{w}^T \vec{x_j}}$$

که در رابطه‌ی بالا،  $y_j$  یک  $\pm 1$  است و لذا  $y_j$  متناظر با آن حتماً مثبت است.  $y_j$  به جیب نمونی  $y_j$  است.

(ج)

$$\begin{aligned}
 \text{مرز جداکننده: } g(\vec{x}) &= \vec{w}^T \Phi(\vec{x}) + b = \left( \sum_{i=1}^n \lambda_i y_i \Phi(\vec{x_i}) \right)^T \Phi(\vec{x}) + b \\
 &= \sum_{i=1}^n \lambda_i y_i \underbrace{\Phi(\vec{x_i})^T \Phi(\vec{x})}_{k(\vec{x_i}, \vec{x})} + b = \sum_{i=1}^n \lambda_i y_i k(\vec{x_i}, \vec{x}) + b
 \end{aligned}$$

طبق رابطه‌ی بالا، مرز جداکننده توسط کرنل بدست می‌آید. در نرم Summation فقط کافیست  $\vec{w}$  را وارد کنیم همچون مقدار  $\lambda_i$  برای سایر داده‌ها صفر است.

ماتریس  $X$  در بردار  $y$  را به صورت زیر معرفی می‌کنیم:

$$X = \begin{bmatrix} \text{---} x_1^T \text{---} \\ \vdots \\ \text{---} x_n^T \text{---} \end{bmatrix}$$

$$y = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$$

لذا تابع  $L(w)$  را می‌توانیم به صورت زیر بنویسیم:

$$L(w) = \|Xw - y\|_2^2 + \lambda \|w\|_2^2 = (Xw - y)^T (Xw - y) + \lambda w^T w$$

$$= w^T X^T X w - w^T X^T y - y^T X w + y^T y + \lambda w^T w$$

$$\nabla_w L(w) = 2X^T X w - X^T y - X^T y + 2\lambda w = 0$$

$$\Rightarrow (X^T X + \lambda I) w = X^T y$$

$$\Rightarrow \boxed{w = (X^T X + \lambda I)^{-1} X^T y}$$

در رابطه بالا،  $I$  ماتریس همانی است.